#### 1 Bayesian Linear Regression

$$\begin{split} P(t|x,\bar{z},\bar{z}) &= \int_{-\infty}^{\infty} P(t|x,\bar{\omega}) P(\bar{\omega}|\bar{z},\bar{z}) \, d\omega \\ \frac{1}{2} &\neq P(t|x,\bar{\omega}) = N(t|y(x,\bar{\omega}),\beta^2) = N(t|w^2(x),\beta^2) \\ &\cdot P(\bar{\omega}) = N(u|v,\alpha^2|1) \\ &\cdot P(\bar{\omega}|\bar{z},\bar{\omega}) \approx P(\bar{\omega}) \propto \lim_{n \to \infty} N(t|w^2(x),\beta^2) - N(u|v,\alpha^2|1) \\ &\leq \exp F^{\frac{1}{2}}_{\infty}(t|x,w^2(x),\phi(x),\bar{\omega}) - 2w^{\frac{1}{2}}_{\infty}(t|x),b^2) + 2w^{\frac{1}{2}}_{\infty}(t|x) \\ &= \exp F^{\frac{1}{2}}_{\infty}(t|x,w^2(x),\phi(x),\bar{\omega}) - 2w^{\frac{1}{2}}_{\infty}(t|x),b^2) + 2w^{\frac{1}{2}}_{\infty}(t|x) \\ &= \exp F^{\frac{1}{2}}_{\infty}(t|x,w^2(x),\phi(x),\bar{\omega}) - 2w^{\frac{1}{2}}_{\infty}(t|x),b^2) + 2w^{\frac{1}{2}}_{\infty}(t|x) \\ &\Rightarrow S_w^{-1} \approx \alpha t + \frac{1}{2}w^2(t|x),b^2(t|x) + 2w^{\frac{1}{2}}_{\infty}(t|x),b^2(t|x) \\ &\Rightarrow S_w^{-1} \approx (1+x),b^2(t|x),b^2(t|x) + (u^2\phi(x))^2) \cdot \exp F^{\frac{1}{2}}_{\infty}(w-m_0)^2 S_w^{-1}(w-m_0) \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = M(w|m_0,S_w) \\ P(t|x,\bar{x},\bar{t}) = \int_{-\infty}^{\infty} P(t|x,\bar{w}) P(u|\bar{x},\bar{x}) \, dw \quad &\leq \int_{-\infty}^{\infty} \exp F^{\frac{1}{2}}_{\infty}(t^2-t|w^2+t|x) + (u^2\phi(x))^2) \cdot \exp F^{\frac{1}{2}}_{\infty}(w-m_0)^2 S_w^{-1}(w-m_0) \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = M(w|m_0,S_w) \\ P(t|x,\bar{x},\bar{t}) = \int_{-\infty}^{\infty} P(t|x,\bar{w}) P(u|\bar{x},\bar{x}) \, dw \quad &\leq \int_{-\infty}^{\infty} \exp F^{\frac{1}{2}}_{\infty}(t^2-t|w^2+t|x) + (u^2\phi(x))^2) \cdot \exp F^{\frac{1}{2}}_{\infty}(w-m_0)^2 S_w^{-1}(w-m_0) \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = M(w|m_0,S_w) \\ P(t|x,\bar{x},\bar{t}) = \int_{-\infty}^{\infty} \exp F^{\frac{1}{2}}_{\infty}(t^2-t|x) + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = \exp F^{\frac{1}{2}}_{\infty}(t|x) + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = \int_{-\infty}^{\infty} \exp F^{\frac{1}{2}}_{\infty}(t|x) + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 + (u^2\phi(x))^2 \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = \exp F^{\frac{1}{2}}_{\infty}(t|x) + (u^2\phi(x))^2 \\ &\cdot P(\bar{\omega}|\bar{x},\bar{t}) = \exp F^{\frac{1}{2}}_{\infty}(t|x) + (u^2\phi(x))^2 + (u^2\phi(x)$$

#### 2 Linear Regression

#### 2.1 Feature selection

(a) In the feature selection stage, please apply polynomials of order M=1 and M=2 over the input data with dimension D=11. Please evaluate the corresponding RMS error on the training set and valid set.

我先將 data X 與 T 合併一起 shuffle, 然後以 8:2 拆成 training 與 validation data。這邊嘗試使用兩種方法:

第一種方法是利用 gradient descent 的方法( $w^* = w - lr \times \frac{\partial L}{\partial w}$ )去更新 linear regression model 的 weight,然後去求取每個 epoch 帶入 RMS 計算出來的 loss。第二種方法是直接利用公式 $w_{ML} = (\Phi^T \Phi)^{-1} \Phi^T t$ ,其中 $\Phi$ 可以由 $y(x,w) = \sum_{j=0}^{M-1} w_j \Phi_j(x) = w^T \Phi(x)$ 推得,最後代入RMS =  $\sqrt{\frac{\sum_{t=1}^n (y-\hat{y})^2}{n}}$ ,計算 RMS error 的結果。

### Method 1: Gradient descent

enoch: 1995 / 20000

traing loss: 0.5837713392134929 validation loss: 0.5999877232894505

epoch: 19996 / 20000

traing loss: 0.5837625801755816 validation loss: 0.5999776262632301

epoch: 19997 / 20000

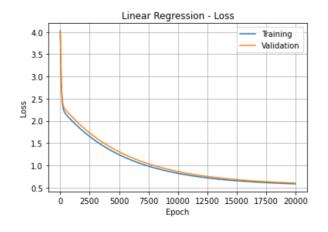
traing loss: 0.5837538225995597 validation loss: 0.5999675308622933

epoch: 19998 / 20000

traing loss: 0.5837450664851666 validation loss: 0.5999574370863594

epoch: 19999 / 20000

traing loss: 0.5837363118321403 validation loss: 0.599947344935149



## Method 2: $w_{ML} = (\boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T t$

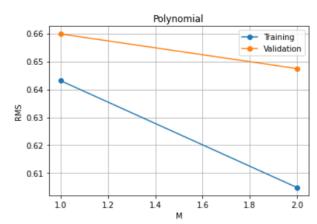
-----Polynomial-----

M=1

RMS train: 0.64310530043101 RMS val : 0.6598255614779065

M=2

RMS train: 0.6048685472553934 RMS val : 0.6474326189304004



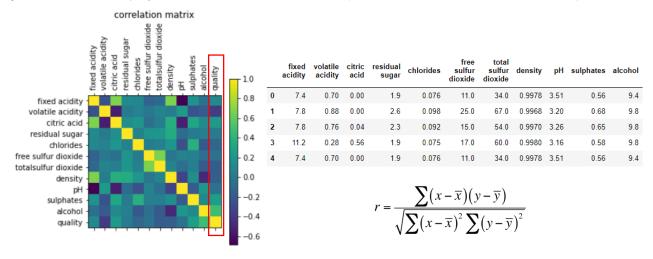
從上圖可知,當 Polynomial order M=1 時, training set 的 RMS error 約為 0.64310, validation set 的 RMS error 約為 0.65982;當 Polynomial order M=2 時, training set 的 RMS error 約為 0.6048, validation set 的 RMS error 約為 0.6474。可以發現當 Polynomial order M 變高的時候, training與 validation的 RMS都有下降的趨勢,表示較複雜的模型(Polynomial order M=2)對於這個 dataset 能有較好的學習結果。

# (b) How will you analyze the weights of the polynomial model M = 1 and select the most contributive feature?

這邊也嘗試了使用兩種方法來決定哪一個 feature 對整個模型的影響是最大的。

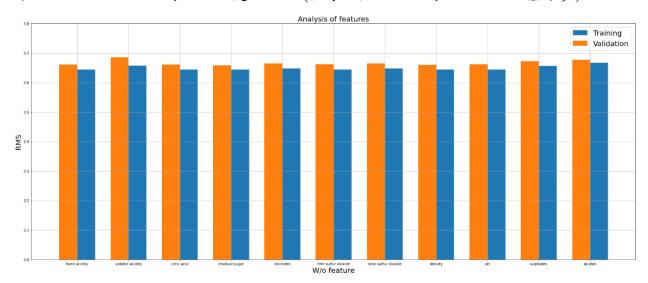
#### **Method 1: Correlation**

第一種方法是去觀察 quality 與所有 feature 之間的 correlation。Correlation 越高代表兩者之間相互的關係越強,如果拿一個 feature 與 quality 去做計算 correlation,就可以知道不同 feature 與 quality 之間的相關性。觀察以下的 correlation matrix 可以發現這些 feature 與 quality 之間的 correlation 相差不大,代表每一個 feature 之間的 contribution 是差不多的,如果硬要選出 contribution 前幾名的 feature,alcohol 大概比其他的 feature 的 contribution 再高一些。



#### Method 2: Remove one of the features to calculate the corresponding RMS error

第二種方法是透過移除其中一種 feature,並保留其他的 feature,再計算出 Polynomial order M=1 時對應的 Training RMS error 與 Validation RMS error。由下圖可知,移除其中一種 feature 對應算出來的 RMS error 相差沒有很大,所以推測每一個 feature 之間的 contribution 差不多。如果要選出 most contributive 的 feature, alcohol 的移除會導致 error 提升最顯著,所以 most contributive 的 feature 是 alcohol (但每一個 feature 的 contribution 差不多)。



#### 2.2 Maximum likelihood approach

(a) Which basis function will you use to further improve your regression model, polynomial, Gaussian, Sigmoid, or hybrid?

利用 Polynomial, Gaussian 與 Sigmoid 三種 basis function 分別計算在 M=1 和 M=2 時 training 和 validation 的 RMS。可以發現使用 Polynomial 時,training 與 validation RMS 都有不錯的表現(RMS 小),因此使用 Polynomial 來提升我的 regression model。

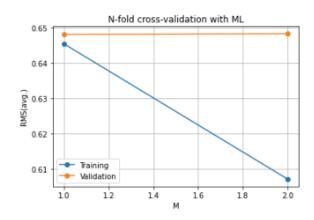
```
-----Sigmoidal-----
-----Polynomial-----
                             -----Gaussian-----
                             M=1
                             RMS train: 0.7592669615485866
RMS train:
          0.64310530043101
                                                          RMS train:
                                                                      0.6412945700979797
          0.6598255614779065
                             RMS val:
                                       0.8008020247068542
                                                           RMS val:
                                                                      0.6648415660339035
                             M=2
M=2
RMS train: 0.6048685472553934
                             RMS train: 0.6923484347609844
                                                          RMS train: 0.6042039194969999
RMS val : 0.6474326189304004 RMS val:
                                      0.7566264445030028
                                                          RMS val:
                                                                      0.6569981607249855
```

(b) Introduce the basis function you just decided in (a) to the linear regression model and analyze the result you get. (Hint: You might want to discuss the phenomenon when the model becomes too complex.)

我使用 Polynomial 作為 basis function,相較於其他兩個,在 training 與 validation 的 RMS 上有更好的表現。可以觀察到 Polynomial, Gaussian 與 Sigmoid 在 M=1 時, RMS 都是相對於 M=2 時還要高,代表在這個問題中,較複雜的模型(M=2)並不會讓模型 over fitting。

$$y(\mathbf{x},\mathbf{w}) = w_0 + \sum_{i=1}^D w_i x_i + \sum_{i=1}^D \sum_{j=1}^D w_{ij} x_i x_j \quad (M=2)$$

(c) Apply N-fold cross-validation in your training stage to select at least one hyper-parameter (order, parameter number, ...) for the model and do some discussion (underfitting, overfitting).



N-fold cross-validation 主要作用是要防止因為模型過於複雜所導致的 overfitting。這裡使用 N-fold cross-validation 並將 N 設為 10,作法是將資料隨機平均分成 10 個集合,然後將某一個集合作為 Validation data,剩下 9 個集合作為 Training data,如此重複進行直到每一個集合都被當作 Validation data 為止。由圖可知,在 Polynomial order M=2 時,training 的 RMS 優於 M=1 時的 RMS,而且有明顯的下降。但 Validation 的 RMS 並沒有特別顯著的提升。

#### 2.3 Maximum a posterior approach

(a) What is the key difference between the maximum likelihood approach and the maximum posterior approach?

### **Maximum Likelihood Estimation (MLE)**

假設資料  $x_1, x_2, ..., x_n$ 是 i.i.d (Independent and identical distribution)的一組抽樣,  $X = (x_1, x_2, ..., x_n)$ 。MLE 的估計方法推導如下:

$$\theta_{MLE} = \operatorname{argmax} \ P(X|\theta)$$

$$= \operatorname{argmax} \ P(x_1;\theta)P(x_2;\theta)\cdots P(x_n;\theta)$$

$$= \operatorname{argmax} \ \log \prod_{i=1}^{n} P(x_i;\theta)$$

$$= \operatorname{argmax} \ \sum_{i=1}^{n} log P(x_i;\theta)$$

$$= \operatorname{argmin} - \sum_{i=1}^{n} log P(x_i;\theta)$$

### Maximum A Posterior (MAP)

假設資料  $x_1, x_2, ..., x_n$ 是 i.i.d (Independent and identical distribution)的一組抽樣,  $X = (x_1, x_2, ..., x_n)$ 。MAP 的估計方法推導如下:

$$\theta_{MAP} = \operatorname{argmax} \ P(\theta|X)$$

$$= \operatorname{argmin} - \log P(\theta|X)$$

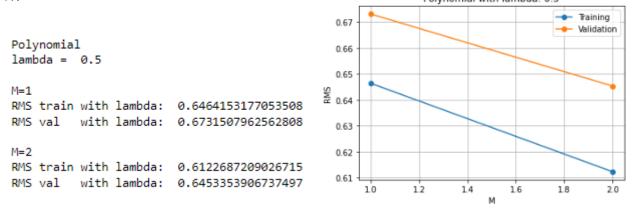
$$= \operatorname{argmin} - \log P(X|\theta) - \log P(\theta) + \log P(X)$$

$$= \operatorname{argmin} - \log P(X|\theta) - \log P(\theta)$$

由以上公式,可以得出,當 prior follow uniform distribution 時,MLE 是 MAP 的一種特殊情況。另外,在 MAP 中使用一個 Gaussian distribution 的 prior probability 等價於 MLE 中採用的 L2 regularization。因此,原本的 weight function, $w_{ML} = (\Phi^T \Phi)^{-1} \Phi^T t$ 會加入 lambda 修正項變成 $w_{ML} = (\Phi^T \Phi + \lambda I)^{-1} \Phi^T t$ ,目的是為了能夠在高階時有效降低 over fitting 的現象。

# (b) Use the maximum a posteriori approach method to retest the model in 2.2 you designed. You could choose Gaussian distribution as a prior.

下面是使用 MAP 的方法,並取 lambda = 0.5 ,重做第二題所得到 RMS 的結果。從圖中可知,當 Polynomial order M= 1 時, training RMS 約為 0.64641, validation RMS 約為 0.67315。在 Polynomial order M=2 時, training RMS 約為 0.61227, validation RMS 約為 0.64534,可以發現加上 lambda 修正項後,有讓模型在更高階時讓 RMS error 下降的更明顯。



# (c) Compare the result between the maximum likelihood approach and maximum a posteriori approach. Is it consistent with your conclusion in (a)?

下圖是比較使用 MLE(左圖)與 MAP(右圖),可以發現 MAP 在 M=2 時讓 RMS error 下降的更明顯,能夠降低 over fitting 的現象。

